Evoliucinio Neuroninio Tinklo Iris Klasifikacijai Analizė

Jonas Kirkilovskis

2026 m. gegužės 25 d.

1 Užduoties tikslas

Šio projekto tikslas yra sukurti daugiasluoksnį neuroninį tinklą, kuris atliktų Iris gėlių klasifikaciją į tris klases: Iris-setosa, Iris-versicolor ir Iris-virginica. Tinklas yra apmokomas mano realizuotu evoliuciniu algoritmu.

Pagal užduoties reikalavimus:

- Tinklas turi turėti 3 sluoksnius: įvesties, paslėptą ir išvesties.
- Paslėptame sluoksnyje naudojama sigmoidinė aktyvacijos funkcija.
- Išvesties neuronas yra vienas ir naudoja tiesinę aktyvacijos funkciją.
- Klasifikacija atliekama pagal intervalus:
  - $y < 1.5$ – Iris-setosa (1 klasė)
  - $1.5 \leq y < 2.5$ – Iris-versicolor (2 klasė)
  - $y \geq 2.5$ – Iris-virginica (3 klasė)
- Tinklo kokybė vertinama naudojant vidutinę kvadratinę klaidą (angl. *Mean Squared Error*, MSE).
- Galutinis rezultatas vertinamas pagal klasifikacijos tikslumą procentais (accuracy).

2 Duomenų apdorojimas

Duomenys yra skaitomi iš CSV failo. Kiekvienas įrašas turi 4 įvesties požymius (žiedlapio ir taurėlapių ilgis bei plotis) ir vieną klasės žymą. Klasės yra koduojamos į skaitines reikšmes: Iris-setosa $\rightarrow$ 1, Iris-versicolor $\rightarrow$ 2, Iris-virginica $\rightarrow$ 3. Duomenys saugomi struktūroje `IrisData(features, target)`.

2.1 Duomenų normalizavimas

Kadangi pradiniai Iris duomenų rinkinio požymiai skiriasi savo skaitiniais rėžiais, programoje realizuotas **Min-Max normalizavimas** (angl. *Min-Max scaling*). Visi įvesties požymiai buvo transformuoti į rėžius $[0, 1]$ pagal formulę:

$$x_{normalized} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Šis žingsnis apsaugo paslėptojo sluoksnio sigmoidinę funkciją nuo saturacijos (persisotinimo) efektų bei užtikrina, kad evoliucijos ir mutacijos metu visi 4 požymiai turėtų tolygią įtaką tinklo svorių optimizavimui.

3 Neuroninio tinklo architektūra

Naudojamas pilnai sujungtas 3 sluoksnių neuroninis tinklas su struktūra $4 \to 6 \to 1$:

3.1 Įvesties sluoksnis

Turi 4 neuronų įvestis, kurios priima sunormalizuotus gėlių požymius ir perduoda juos į paslėptą sluoksnį.

3.2 Paslėptas sluoksnis

Sudaromas iš 6 neuronų. Kiekvienas neuronas skaičiuoja svertinę įvesčių sumą ir pritaiko sigmoidinę aktyvacijos funkciją:

$$h_j = \sigma\left(\sum_{i=1}^{4} x_i w_{ij} + b_j\right), \quad \text{kur} \quad \sigma(x) = \frac{1}{1+e^{-x}}$$

3.3 Išvesties sluoksnis

Turi vieną neuroną, kuris naudoja tiesinę aktyvacijos funkciją (išveda tiesioginę svertinę sumą iš paslėpto sluoksnio):

$$y = \sum_{j=1}^{6} h_j w_j + b_{out}$$

Gauta reikšmė y yra tiesiogiai naudojama galutinei klasei nustatyti.

4 Evoliucinis algoritmas

Mokymas vykdomas naudojant autentiškai realizuotą evoliucinį algoritmą, kuris susideda iš šių žingsnių:

4.1 1. Inicializacija

Sukuriama pradinė atsitiktinių neuroninių tinklų populiacija. Šiame tyrime pasirinktas populiacijos dydis $N = 500$ individų. Kiekvieno tinklo svoriai inicializuojami atsitiktinėmis reikšmėmis intervale $[-1, 1]$.

4.2 2. Vertinimas

Kiekvienas populiacijos tinklas simuliuoja visą duomenų rinkinį ir jo tinkamumas (angl. *fitness*) įvertinamas skaičiuojant MSE:

$$Standard_MSE = \frac{1}{n}\sum_{k=1}^{n}(y_{true}^{(k)} - y_{pred}^{(k)})^2$$

4.3 3. Atranka (Selection) ir Elitizmas

Populiacija surūšiuojama didėjimo tvarka pagal jų MSE reikšmes. Taikomas **elitizmo principas** – top 10% geriausių individų (mažiausia klaida) yra tiesiogiai perkeliami į kitą generaciją be jokių pakeitimų, taip išsaugant geriausius rastus sprendimus.

4.4 4. Dauginimasis ir Mutacija

Likę 90% naujosios populiacijos vietų užpildomi imant atsitiktinius tėvus iš elito grupės ir sukuriant jų kopijas (vaikus), kuriems pritaikomas mutacijos operatorius. Mutacijos metu prie esamų svorių pridedamas Gauso triukšmas:

$$w_{new} = w_{old} + \mathcal{N}(0, \text{rate})$$

Programoje realizuotas kintantis mutacijos greitis (angl. *adaptive mutation rate*), kuris mažėja bėgant generacijoms:

$$\text{rate} = 0.1 + 0.25 \cdot \left(1 - \frac{gen}{maxGen}\right)$$

Tai užtikrina plačią globalią paiešką pradinėse stadijose ir smulkų, tikslų svorių nugludinimą algoritmo pabaigoje. Eksperimente $maxGen = 1000$.

5 Rezultatų vertinimas

Po apmokymo (per 1000 generacijų) modelio kokybė ir naudingumas klasifikacijai vertinami analizuojant vidutinės kvadratinės klaidos (MSE) mažėjimą bei galutinį gėlių atpažinimo tikslumą procentais.

Eksperimentinio tyrimo metu nustatyta, kad pradinėse evoliucijos generacijose tinklo MSE vertė krenta sparčiausiai, o vėliau mokymosi kreivė stabilizuojasi ir pasiekia konvergenciją. Galutinė pasiekta vidutinė kvadratinė klaida po 1000 generacijų nusistovi ties maždaug **0.02 − 0.025** rėžiais. Tai rodo, kad evoliucinis algoritmas sugeba sėkmingai atrinkti tokius svorių ir poslinkių rinkinius, kurie tiksliai aproksimuoja norimas tikslines klases.

Analizuojant modelio klasifikavimo gebą su visu Iris duomenų rinkiniu, gauti stabilūs ir aukšti rezultatai. Priklausomai nuo pradinės atsitiktinės populiacijos inicializacijos, galutinis gėlių klasifikavimo tikslumas (angl. *accuracy*) reguliariai vyrauja tarp **96% ir 98%**. Atskirų eksperimentų metu, sėkmingai sukonvergavus populiacijos elitui, tikslumo rodiklis geba pakilti ir viršyti 98% ribą. Tokie rezultatai patvirtina, kad realizuotas 3 sluoksnių neuroninis tinklas, valdomas evoliucinio algoritmo, yra visiškai tinkamas ir efektyvus šio pobūdžio netiesinės klasifikacijos uždaviniams spręsti.

6 Išvada

Sukurtas evoliucinis neuroninis tinklas įrodė, kad daugiasluoksnės struktūros gali būti sėkmingai optimizuotos nenaudojant tradicinių gradientinių metodų (tokių kaip *backpropagation*).

Elitizmo strategija užtikrina algoritmo konvergavimą (rezultatai neprastėja), o kintantis mutacijos greitis kartu su įvesties duomenų normalizavimu padeda išvengti ankstyvo užstrigimo lokaliuose ekstremumuose. Gauti rezultatai (viršijantys 98% tikslumą) patvirtina pasirinktos architektūros ir evoliucinio algoritmo sinergijos efektyvumą sprendžiant netiesinės klasifikacijos uždavinius.